

HỌC PHẦN

Xử lý dữ liệu lớn

Big Data — Chương trình Thạc sĩ Khoa học máy tính

Chương 2 — Thu thập dữ liệu lớn

TS. Vũ Ngọc Thanh Sang

Khoa Công nghệ Thông tin — Trường Đại học Sài Gòn

MTDL522
3 tín chỉ

Nội dung chương

Mục	Tên mục	Nội dung chính	Tuần
2.1	Các bước trong xử lý dữ liệu	Thu thập; khám phá và tiền xử lý; phân tích; giải thích kết quả; biến hiểu biết sâu sắc thành hành động	4
2.2	Làm sạch và tích hợp dữ liệu	ETL/ELT, Kafka, Flume, Sqoop, NiFi, CDC, định dạng dữ liệu; chất lượng dữ liệu, khử trùng lặp, đối sánh thực thể, giá trị thiếu, siêu dữ liệu	5
2.3	Lưu trữ dữ liệu và điện toán đám mây	Hiệu suất, khả năng mở rộng, chi phí; nền tảng nội bộ, đám mây công cộng và mô hình lai	6
–	Tình huống nghiên cứu và tổng kết	NEU IO Portal; pipeline thu thập cho trung tâm dữ liệu đại học; câu hỏi thảo luận; bài tập tự học	6

Ranh giới: HDFS, NoSQL, CAP, mô hình xử lý luồng ở Chương 3; Spark/Hive ở Chương 4; học máy ở Chương 5.

Kafka ở đây là công cụ thu nhận, tích hợp.

Xử lý dữ liệu lớn — Chương 2: Thu thập dữ liệu lớn

Chuẩn đầu ra và mục tiêu học tập

SAU CHƯƠNG NÀY, HỌC VIÊN CÓ THỂ

1. Mô tả vòng đời xử lý dữ liệu và vai trò của từng bước. [CLO4]
2. So sánh phương thức thu thập: lô, đẩy, luồng, CDC. [CLO4]
3. Lựa chọn công cụ tích hợp theo đặc trưng nguồn. [CLO4]
4. Thiết kế quy tắc chất lượng và làm sạch ở quy mô lớn. [CLO4]
5. Ước lượng chi phí; chọn nội bộ, đám mây hay lai. [CLO5]

CLO4 (mục 2.1, 2.2): hiểu các bước xử lý dữ liệu lớn, đánh giá chiến lược tiếp cận từng bước.


CLO5 (mục 2.3): đánh giá, lựa chọn giải pháp lưu trữ theo hiệu suất, mở rộng, chi phí.

MỤC 2.1

Các bước trong xử lý dữ liệu

Thu thập, khám phá, tiền xử lý, phân tích, truyền đạt kết quả và hành động

Quy trình khoa học dữ liệu: vòng đời sáu bước



Hình 2.1: Vòng đời xử lý dữ liệu. Nguồn: tác giả tổng hợp

Luận điểm của chương

Dữ liệu thu thập sai hoặc thiếu không thể bù đắp hoàn toàn bằng mô hình phân tích phức tạp.

- Chuỗi bước lặp: lỗi ở bước đầu lan truyền, khuếch đại ở các bước sau [1, 3].

Thu thập dữ liệu: khái niệm

Định nghĩa. Thu thập dữ liệu là quá trình xác định, truy cập và đưa dữ liệu từ các nguồn vào hệ thống lưu trữ/xử lý, kèm theo **siêu dữ liệu** (*metadata*) mô tả nguồn gốc, thời điểm và lược đồ [1].


Đặc trưng nguồn (cấu trúc, tốc độ, quyền truy cập, khả năng chịu tải) quyết định phương thức và công cụ thu thập.




Hình 2.2: Các nhóm nguồn dữ liệu. Theo bài giảng CNTT

Bốn phương thức thu thập dữ liệu

(a) Kéo theo lô (batch pull)




(b) Đẩy (push)



(c) Luồng (streaming)



(d) Thu thập thay đổi (CDC)



Hình 2.3: Bốn phương thức thu thập dữ liệu. Nguồn: tác giả tổng hợp

Đặc điểm của bốn phương thức thu thập

- ▶ **Kéo theo lô**: hệ đích chủ động truy vấn nguồn theo lịch; đơn giản nhưng gây tải lên nguồn.
- ▶ **Đẩy**: nguồn chủ động gửi khi có dữ liệu; hệ đích phải chịu được đột biến tải.
- ▶ **Luồng**: sự kiện đi qua lớp đệm bền vững; nhiều bên tiêu thụ độc độc lập.
- ▶ **CDC** (change data capture): đọc nhật ký giao dịch, không truy vấn bảng nghiệp vụ.

So sánh các phương thức thu thập

Tiêu chí	Kéo theo lô	Đẩy	Luồng	CDC
Độ trễ dữ liệu	phút – giờ (theo T)	giây	mili giây – giây	giây
Tải lên hệ nguồn	cao khi quét bảng lớn	do nguồn kiểm soát	thấp (ghi vào broker)	thấp (đọc nhật ký)
Phát hiện bản ghi bị xóa	khó (cần so sánh)	tùy ứng dụng	tùy thiết kế sự kiện	có
Độ phức tạp vận hành	thấp	trung bình	cao	cao
Công cụ tiêu biểu	Sqoop, Spark JDBC	HTTP, Flume	Kafka, NiFi	Debezium, Kafka Connect

Đánh đổi giữa các phương thức thu thập

Độ tươi dữ liệu khi kéo theo lô

Chu kỳ nạp T , thời gian xử lý t_p :

$$\bar{L} \approx \frac{T}{2} + t_p, \quad L_{\max} \approx T + t_p.$$

Giảm T làm tăng tần suất truy vấn và tải lên nguồn.

- ▶ Đánh đổi chính: **độ trễ** $\leftrightarrow$ **chi phí, độ phức tạp**.
- ▶ Thực tế thường kết hợp: CDC cho bảng thay đổi nhiều, lô cho dữ liệu tham chiếu, luồng cho sự kiện.
- ▶ Lựa chọn xuất phát từ yêu cầu về độ tươi.

Yêu cầu thiết kế tầng thu nhận

Yêu cầu về luồng dữ liệu

- ▶ **Thông lượng**: tốc độ đỉnh, không chỉ trung bình.
- ▶ **Độ trễ**: từ thời điểm phát sinh đến khi sẵn sàng sử dụng.
- ▶ **Đảm bảo giao nhận**: mất, trùng hay đúng một lần.
- ▶ **Áp lực ngược** (backpressure): cơ chế khi hệ đích chậm hơn nguồn.

Yêu cầu về độ tin cậy và vận hành

- ▶ **Tính lũy đẳng** (idempotency): nạp lại không tạo kết quả sai.
- ▶ **Kiểm tra lược đồ** và vùng cách ly dữ liệu lỗi.
- ▶ **Giám sát**: độ trễ tiêu thụ (consumer lag), tỷ lệ lỗi, khối lượng theo nguồn.

Khám phá dữ liệu (EDA) ở quy mô lớn

- ▶ **Khám phá dữ liệu** (*exploratory data analysis, EDA*): dùng thống kê mô tả và đồ thị để hiểu cấu trúc, phát hiện bất thường, hình thành giả thuyết [Tukey, 1977].
- ▶ Ở quy mô lớn, trung vị hay số giá trị phân biệt tính chính xác đòi hỏi xáo trộn toàn bộ dữ liệu.
- ▶ Giải pháp: tính phân tán một lượt quét, **thuật toán xấp xỉ** có cận sai số, **lấy mẫu** có kiểm soát.

Các bước khám phá dữ liệu



Hình 2.4: Các bước khám phá dữ liệu ở quy mô lớn. Nguồn: tác giả tổng hợp

Thông kê mô tả và phân vị xấp xỉ với PySpark

```
from pyspark.sql import functions as F
df = spark.read.parquet("hdfs:///lake/clean/orders/")
# count, mean, stddev, min, max: một lượt quét
df.select("amount", "quantity").describe().show()
# Phân vị xấp xỉ với sai số hạng tương đối 1%
q = df.approxQuantile("amount", [0.25, 0.5, 0.75, 0.99], 0.01)
# Số khách hàng phân biệt (HyperLogLog++), sai số ~2%
df.agg(F.approx_count_distinct("customer_id", rsd=0.02)).show()
```

- ▶ `describe()` chỉ cần n , $\sum x$, $\sum x^2$: một lượt quét song song.
- ▶ `approxQuantile` (biến thể Greenwald–Khanna): hạng lệch không quá εN ; $\varepsilon = 0$ chính xác nhưng rất tốn kém.

Lấy mẫu để khám phá dữ liệu lớn

- ▶ **Ngẫu nhiên đơn giản:** `df.sample(fraction=0.01, seed=42)`.
- ▶ **Phân tầng:** `df.sampleBy("khoa", fractions)`; giữ nhóm nhỏ nhưng quan trọng.
- ▶ **Reservoir sampling** cho luồng: mẫu cỡ k cố định, mỗi phần tử được chọn với xác suất k/n [Vitter, 1985].
- ▶ Sai số chuẩn $SE(\bar{x}) = \sigma/\sqrt{n}$ gần như không phụ thuộc cỡ tổng thể N khi $n \ll N$: mẫu 10^5 bản ghi đủ cho thống kê tổng quát.
- ▶ Hạn chế: nhóm hiếm và ngoại lai có thể biến mất; cần ghi rõ kết quả tính trên mẫu.

Tiền xử lý dữ liệu

- ▶ **Tiền xử lý dữ liệu** (*data pre-processing*): đưa dữ liệu đã làm sạch về dạng phù hợp phương pháp phân tích.
- ▶ Loại bản ghi trùng lặp; xử lý giá trị thiếu.
- ▶ Chuẩn hóa kiểu dữ liệu, đơn vị và múi giờ.
- ▶ Phát hiện và xử lý ngoại lai theo ngữ cảnh.
- ▶ Mã hóa biến phân loại (one-hot, chỉ số hóa).
- ▶ Co giãn thang đo khi thuật toán nhạy với độ lớn.
- ▶ Ghép các đặc trưng thành vector đầu vào.

Co giãn thang đo: ba phép phổ biến

$$z = \frac{x - \mu}{\sigma}$$

chuẩn hóa (standardization)

$$x' = \frac{\bar{x} - x_{\min}}{x_{\max} - x_{\min}}$$

min–max về $[0, 1]$

$$x'' = \frac{x - \text{median}}{\text{IQR}}$$

bền vững với ngoại lai

- ▶ Cần co giãn: thuật toán dựa trên khoảng cách (k-means, kNN), tối ưu bằng gradient.
- ▶ Thường không cần: cây quyết định, rừng ngẫu nhiên.
- ▶ Spark MLlib: `StandardScaler`, `MinMaxScaler`, `RobustScaler`.

Rò rỉ dữ liệu trong tiền xử lý

Rò rỉ dữ liệu (data leakage): thông tin không có lúc dự báo lọt vào huấn luyện, khiến độ đo kiểm tra lạc quan giả tạo.

- ▶ Đặc trưng được tính từ dữ liệu tương lai.
- ▶ Học tham số tiền xử lý (trung bình, mã hóa) trước khi chia tập.
- ▶ Cột gần như mã hóa nhãn; một đối tượng có ở cả hai tập.

Nguyên tắc phòng tránh

Chia tập trước; `fit` chỉ trên tập huấn luyện, `transform` trên các tập còn lại.
Chia theo thời gian hoặc theo đối tượng khi phù hợp.

Phân tích dữ liệu: bốn mức độ

Mức	Câu hỏi	Kỹ thuật tiêu biểu
Mô tả (descriptive)	Điều gì đã xảy ra?	tổng hợp, OLAP, báo cáo, dash-board
Chẩn đoán (diagnostic)	Vì sao xảy ra?	phân rã theo chiều, tương quan, phân tích nguyên nhân
Dự đoán (predictive)	Điều gì có thể xảy ra?	hồi quy, phân lớp, dự báo chuỗi thời gian (Chương 5)
Đề xuất (prescriptive)	Nên làm gì?	tối ưu hóa, mô phỏng, thử nghiệm có đối chứng

Giá trị và độ phức tạp tăng dần theo mức. Ở quy mô lớn, ba mức đầu ánh xạ tới truy vấn tương tác, xử lý theo lô, huấn luyện phân tán.

Giải thích kết quả: dữ liệu, mã hóa và nhiệm vụ

- ▶ **Trực quan hóa dữ liệu** (*data visualization*) ánh xạ dữ liệu sang kênh thị giác để phục vụ một nhiệm vụ phân tích.

Dữ liệu

Bản ghi, độ đo, thời gian, vị trí, nhóm.


Mã hóa thị giác

Vị trí, chiều dài, góc, diện tích, màu, hình dạng.

Nhiệm vụ

So sánh, phát hiện bất thường, theo dõi xu hướng, kiểm tra giả thuyết.

Độ chính xác của các kênh thị giác



Hình 2.5: Thứ hạng độ chính xác của các kênh thị giác. Theo Cleveland & McGill (1984)


- ▶ Cleveland & McGill (1984): vị trí và chiều dài được so sánh chính xác hơn góc, diện tích, độ đậm màu.
- ▶ Hệ quả: giá trị định lượng quan trọng mã hóa bằng vị trí/chiều dài; màu và hình dạng dùng để phân nhóm.

Chọn biểu đồ theo câu hỏi phân tích

Câu hỏi	Biểu đồ phù hợp	Ví dụ trong trường đại học	Lưu ý ở quy mô lớn
So sánh	cột, dot plot	sĩ số theo khoa	sắp xếp theo giá trị
Phân phối	histogram, boxplot, mật độ	phân phối điểm học phần	tính trước bin/phân vị
Quan hệ	scatter, heatmap, hexbin	thời gian học LMS và điểm	hexbin khi điểm chồng lấp
Thời gian	đường, vùng	lượt truy cập LMS theo giờ	giảm mẫu chuỗi thời gian

Nguyên tắc: xác định câu hỏi và người ra quyết định trước khi chọn loại biểu đồ. Dữ liệu không gian, cơ cấu, quan hệ mạng: xem Tài liệu đọc thêm Chương 2.

Ví dụ: cùng dữ liệu, hai thông điệp khác nhau



Hình 2.6: Ảnh hưởng của góc trục đến cảm nhận khác biệt (dữ liệu giả lập). Nguồn: tác giả tổng hợp

Ở (a), Khoa D có vẻ gấp nhiều lần Khoa A dù chỉ chênh 5 điểm phần trăm. Cột mã hóa giá trị bằng chiều dài nên trục phải bắt đầu từ 0; khác biệt nhỏ nên dùng dot plot và ghi chú rõ.

Giảm dữ liệu trước khi trực quan hóa

- ▶ Số bản ghi vượt xa số điểm ảnh: hiển thị trực tiếp gây **chồng lấp** (overplotting) và độ trễ cao.
- ▶ Giảm dữ liệu trước khi vẽ: lấy mẫu, tổng hợp trước (pre-aggregation), chia ô (binning, hexbin), giảm mẫu chuỗi thời gian.
- ▶ Dashboard tương tác cần **lớp phục vụ**: bảng tổng hợp, khối dữ liệu (cube), bộ nhớ đệm.
- ▶ Trực quan hóa lũy tiến: hiển thị kết quả gần đúng sớm, tinh chỉnh dần.

Dashboard: phân cấp thông tin




Hình 2.7: Dashboard ba cấp: tín hiệu, ngữ cảnh, chi tiết. Theo bài giảng CNTT

PHÂN CẤP

- ▶ Cấp 1 — tín hiệu: KPI chính, cảnh báo.
- ▶ Cấp 2 — ngữ cảnh: xu hướng, so sánh, phân rã theo nhóm.
- ▶ Cấp 3 — chi tiết: bảng, bản ghi gốc, bằng chứng.

Nguyên tắc của Shneiderman (1996): tổng quan trước, phóng to và lọc, chi tiết khi cần.

Biến hiểu biết sâu sắc thành hành động



Hình 2.8: Chuỗi giá trị từ dữ liệu đến hành động và vòng phản hồi. Nguồn: tác giả tổng hợp

Ví dụ: cảnh báo sớm học vụ

Dữ liệu LMS và điểm giữa kỳ → nhận diện sinh viên ít truy cập, điểm thấp → cố vấn học tập liên hệ → ghi nhận kết quả can thiệp → đánh giá hiệu quả và hiệu chỉnh ngưỡng.

Điều kiện để hiểu biết dẫn tới hành động



Hình 2.9: Kết quả phân tích được trình bày cho người ra quyết định. Theo bài giảng CNTT


- ▶ Điều kiện để hiểu biết dẫn tới hành động: chủ thể chịu trách nhiệm, ngưỡng hành động, kênh thực thi.
- ▶ Đo tác động bằng nhóm đối chứng hoặc thử nghiệm A/B, tránh nhầm tương quan với nhân quả.

MỤC 2.2

Làm sạch và tích hợp dữ liệu

Công cụ, giao thức tích hợp và các kỹ thuật bảo đảm chất lượng dữ liệu

Tích hợp dữ liệu: điểm–điểm và trực tích hợp



Hình 2.10: Số kết nối khi tích hợp điểm–điểm và qua trực tích hợp. Nguồn: tác giả tổng hợp

- **Tích hợp dữ liệu** (*data integration*): hợp nhất nguồn dị biệt thành góc nhìn nhất quán. Điểm–điểm cần $m \cdot n$ bộ chuyển đổi; trực tích hợp (Kafka, NiFi, ESB) còn $m + n$ nhưng phải sẵn sàng cao.

Quy trình ETL: rút trích, chuyển đổi và nạp



Hình 2.11: Quy trình ETL nạp dữ liệu vào kho dữ liệu. Nguồn: tác giả tổng hợp

Đặc điểm của quy trình ETL

- ▶ **Rút trích, chuyển đổi và nạp** (*Extract–Transform–Load, ETL*): quy trình nền tảng của **kho dữ liệu** (*data warehouse*)
[Kimball & Caserta, 2004].
- ▶ Rút trích từ nguồn dị biệt qua JDBC/ODBC, tệp, API.
- ▶ **Vùng đệm** (staging) cách ly các biến đổi nặng khỏi hệ nguồn.
- ▶ Chuyển đổi gồm làm sạch, tích hợp (giải xung đột lược đồ và giá trị) và tổng hợp theo độ chi tiết yêu cầu.

ETL và ELT: vị trí biến đổi


Tiêu chí	ETL	ELT
Vị trí biến đổi	máy chủ ETL hoặc vùng đệm, trước khi nạp	bên trong hồ dữ liệu / kho dữ liệu, sau khi nạp
Lược đồ	lược đồ khi ghi (<i>schema-on-write</i>)	lược đồ khi đọc (<i>schema-on-read</i>), biến đổi bằng SQL/Spark
Dữ liệu thô	thường không giữ lại	giữ lại, cho phép xử lý lại khi quy tắc thay đổi

Nhận định. ELT phổ biến nhờ tách tính toán và lưu trữ (mục 2.3): lưu dữ liệu thô rẻ, tính toán thuê theo nhu cầu. ETL vẫn cần khi phải ẩn danh hóa dữ liệu cá nhân trước khi rời hệ thống nguồn.

Apache Kafka: nhật ký sự kiện làm trực tích hợp

- ▶ LinkedIn phát triển để thu thập nhật ký và sự kiện [Kreps et al., 2011]: xuất bản—đăng ký trên **nhật ký chỉ ghi nối** (append-only log).
- ▶ **Topic** chia thành nhiều **partition**; mỗi bản ghi có **offset** tăng dần.
- ▶ Thứ tự bảo đảm *trong từng partition*; cùng khóa vào cùng partition: $p = \text{hash}(\text{key}) \bmod P$.
- ▶ Kafka lưu và phân phối, không tính toán; xử lý giao cho Spark, Flink (Chương 3–4).
- ▶ Kafka Connect: bộ kết nối nguồn/đích (JDBC, HDFS, S3, CDC).

Kafka: consumer group và lưu giữ



Hình 2.12: Hai consumer group đọc độc lập cùng một topic. Nguồn: tác giả tổng hợp

- ▶ Trong một nhóm, mỗi partition gán cho tối đa một consumer: song song tối đa bằng P .
- ▶ **Lưu giữ** (retention) cho phép **đọc lại** (replay) khi sửa lỗi.


Kafka: ngữ nghĩa giao nhận

Ngữ nghĩa	Ý nghĩa	Rủi ro / điều kiện
Nhiều nhất một lần	xử lý ≤ 1 lần	có thể mất bản ghi
Ít nhất một lần	xử lý ≥ 1 lần	có thể trùng; cần đích lũy đẳng
Đúng một lần	kết quả như xử lý đúng 1 lần	cần phối hợp nguồn, bộ xử lý và đích (giao dịch)

Thực hành phổ biến

Phía ghi: `acks=all, enable.idempotence=true`. Phía đọc: ghi kết quả trước, xác nhận offset sau (ít nhất một lần), kết hợp khóa sự kiện duy nhất để khử trùng lặp ở đích.

Apache Flume: thu gom nhật ký theo agent




Hình 2.13: Luồng Flume nhiều tầng: agent thu gom về HDFS/Kafka. Nguồn: tác giả tổng hợp

- ▶ Sự kiện = header + body; chuyển source—channel—sink theo giao dịch.
- ▶ Source: TAILDIR, syslog, Avro; Channel: bộ nhớ, tệp; Sink: HDFS, HBase, Kafka. Hỗ trợ định tuyến, cân bằng tải, nhân bản [D4].

So sánh Kafka và Flume

Đặc điểm	Apache Kafka	Apache Flume
Mô hình	nhật ký phân tán, xuất bản— đăng ký	thu gom và vận chuyển (đẩy) theo agent
Lưu giữ dữ liệu	bền vững theo chính sách retention	tạm thời trong channel, xóa sau khi giao
Số bên tiêu thụ	nhiều consumer group độc lập	mỗi luồng đến đích đã cấu hình
Đọc lại	có, trong khoảng lưu giữ	không
Nguồn phù hợp	mọi ứng dụng qua producer API, Connect	tệp nhật ký, syslog, RPC
Đích điển hình	bộ xử lý luồng, hồ dữ liệu, nhiều hệ thống	HDFS, HBase (hệ sinh thái Hadoop)

Apache Sqoop: giữa RDBMS và Hadoop



Hình 2.14: Sqoop import song song bằng các tác vụ Map. Nguồn: tác giả tổng hợp


- ▶ Khoảng của cột `--split-by` chia đều: $\Delta = (\max - \min) / m$; khóa phân bố lệch làm mapper mất cân bằng.
- ▶ Sqoop đã vào Apache Attic (2021), còn phổ biến trên cụm Hadoop hiện hữu; thay thế: Spark JDBC, CDC.

Sqoop: import và nạp gia tăng

```
# (1) Nhập bảng vào HDFS dạng Parquet, 8 mapper
sqoop import --connect jdbc:mysql://db-daotao:3306/qldt \
--username etl --password-file /user/etl/.pw \
--table dang_ky_hoc_phan --split-by id -m 8 \
--as-parquetfile --target-dir /lake/raw/qldt/dang_ky
# (2) Nạp gia tăng theo thời điểm cập nhật
sqoop import --connect jdbc:mysql://db-daotao:3306/qldt \
--username etl --password-file /user/etl/.pw --table diem \
--incremental lastmodified --check-column updated_at \
--last-value "2026-09-30 23:59:59" --merge-key id \
--target-dir /lake/raw/qldt/diem
```

- ▶ Mật khẩu đặt trong tệp có phân quyền (`--password-file`), không ghi trực tiếp trên dòng lệnh.
- ▶ `--incremental append`: chỉ thêm dòng có khóa tăng; `lastmodified`: bắt cả dòng bị sửa.


Apache NiFi: điều phối luồng dữ liệu có truy vết



Hình 2.15: Một luồng NiFi gồm các processor nối bằng hàng đợi. Nguồn: tác giả tổng hợp

Đơn vị dữ liệu là **FlowFile** (thuộc tính + nội dung); hàng đợi có ngưỡng tạo áp lực ngược; truy vết từng FlowFile hỗ trợ kiểm toán, gỡ lỗi.

Thu thập dữ liệu thay đổi (CDC)



Hình 2.16: CDC dựa trên nhật ký giao dịch. Nguồn: tác giả tổng hợp

VÍ DỤ MỘT SỰ KIỆN THAY ĐỔI

```
{ "op": "u", "before": { "id": 7, "diem": 6.5 },  
  "after": { "id": 7, "diem": 7.0 },  
  "ts_ms": 1759300000000 }
```

CDC: so sánh các cách tiếp cận

Cách tiếp cận	Bắt xóa	Tải nguồn	Độ trễ
Truy vấn theo cột thời gian	không	cao	phút
Trigger ghi bảng phụ	có	cao (mỗi giao dịch)	giây
Độc nhật ký	có	thấp	giây

- ▶ Sự kiện mang trạng thái trước/sau và loại thao tác, theo thứ tự cam kết [Kleppmann, 2017].
- ▶ Cần **ảnh chụp ban đầu** (snapshot) trước khi đọc nhật ký.
- ▶ Thay đổi lược đồ nguồn cần lan truyền có kiểm soát.

Định dạng dữ liệu và tuần tự hóa

Định dạng	Tổ chức	Lược đồ	Chia tách được	Nén	Phù hợp
CSV	hàng, văn bản	không (chỉ tiêu đề)	có (nếu không nén)	kém	trao đổi đơn giản
JSON	hàng, văn bản bán cấu trúc	tự mô tả, không ràng buộc	JSON Lines: có	kém	API, nhật ký
Avro	hàng, nhị phân	lược đồ đi kèm, hỗ trợ tiến hóa	có	tốt	thông điệp Kafka, vùng thô
Parquet	cột, nhị phân	lược đồ trong footer	có (row group)	rất tốt	phân tích, hồ dữ liệu

Hướng hàng hợp ghi từng sự kiện; hướng cột hợp đọc phân tích: chỉ đọc cột cần, đẩy điều kiện lọc xuống tầng lưu trữ [Melnik et al., 2010]. Lược đồ là hợp đồng dữ liệu giữa bên phát và bên tiêu thụ.

Chọn công cụ tích hợp theo nguồn

Tình huống	Công cụ phù hợp	Lý do chính
Bảng RDBMS lớn, nạp định kỳ	Sqoop, Spark JDBC	song song hóa theo khoảng khóa
Đồng bộ thay đổi RDBMS gần thời gian thực	CDC (Debezium) + Kafka	không quét bảng, bắt được thao tác xóa
Nhật ký từ nhiều máy chủ	Flume hoặc agent + Kafka	thu gom phân tán, chịu lỗi tại chỗ
Sự kiện tốc độ cao, nhiều bên tiêu thụ	Kafka	lưu giữ, đọc lại, consumer group

Tiêu chí đánh giá: độ trễ yêu cầu, khối lượng và tốc độ, khả năng chịu tải của nguồn, ngữ nghĩa giao nhận, khả năng truy vết, kỹ năng vận hành sẵn có, tình trạng duy trì của dự án mã nguồn mở.

Sáu chiều chất lượng dữ liệu và cách đo


Chiều	Ý nghĩa	Độ đo ví dụ
Đầy đủ (completeness)	không thiếu giá trị/bản ghi	$1 - \frac{\#null}{\#bản\ ghi\ kỳ\ vọng}$
Chính xác (accuracy)	phản ánh đúng thực tế	tỷ lệ khớp với nguồn tham chiếu
Nhất quán (consistency)	không mâu thuẫn giữa nguồn/bảng	tỷ lệ vi phạm ràng buộc liên bảng
Kịp thời (timeliness)	sẵn sàng khi cần	$t_{sẵn\ sàng} - t_{sự\ kiện}$; % trong SLA
Duy nhất (uniqueness)	mỗi thực thể một bản ghi	$\frac{\#thực\ thể\ phân\ biệt}{\#bản\ ghi}$
Hợp lệ (validity)	đúng định dạng, miền giá trị	% bản ghi thỏa quy tắc

Tính xác thực (Veracity) được cụ thể hóa thành các chiều đo được. Khung đa chiều: Wang & Strong (1996); kiểm tra tự động ở quy mô lớn: Deequ [Schelter et al., 2018].

Khử trùng lặp ở quy mô lớn

- ▶ Nguồn gốc trùng lặp: gửi lại theo ngữ nghĩa ít nhất một lần, nạp lại cùng một lô, cùng thực thể đến từ nhiều nguồn.
- ▶ **Trùng lặp chính xác**: cùng khóa sự kiện $\Rightarrow$ `dropDuplicates`.
- ▶ **Nhiều phiên bản**: giữ bản mới nhất theo khóa nghiệp vụ bằng hàm cửa sổ.
- ▶ **Trùng lặp gần đúng**: cần đối sánh thực thể (trình bày ở các slide tiếp theo).
- ▶ Chi phí: xáo trộn toàn bộ dữ liệu theo khóa; với dữ liệu luồng cần trạng thái có thời hạn (Chương 3).

Đối sánh thực thể (entity resolution)



Hình 2.17: Quy trình đối sánh thực thể. Nguồn: tác giả tổng hợp

- ▶ Bài toán: xác định các bản ghi cùng chỉ một thực thể khi không có khóa chung (sinh viên trong hệ thống đào tạo, LMS, thư viện).
- ▶ Mô hình xác suất kinh điển: Fellegi & Sunter (1969).
- ▶ Độ tương tự: Jaccard trên tập n-gram
$$J(A, B) = |A \cap B| / |A \cup B|$$
, khoảng cách chỉnh sửa (Levenshtein), so khớp ngày sinh.

Đối sánh thực thể: độ phức tạp và phân khối

Độ phức tạp và phân khối

So sánh mọi cặp: $\binom{N}{2} \approx \frac{N^2}{2}$. Với $N = 10^6$: khoảng 5×10^{11} cặp.

Phân khối thành B khối cỡ N/B (ví dụ theo ngày sinh): số cặp $\approx \frac{N^2}{2B}$. Với $B = 10^4$: khoảng 5×10^7 cặp.

- ▶ Đánh đổi: khóa phân khối quá chặt bỏ sót cặp khớp (giảm độ phủ); quá lỏng làm bùng nổ số cặp và gây dữ liệu lệch.

Cơ chế thiếu dữ liệu

Cơ chế	Ý nghĩa và ví dụ [Rubin, 1976]
MCAR	thiếu hoàn toàn ngẫu nhiên: lỗi truyền ngẫu nhiên
MAR	thiếu phụ thuộc biến quan sát được: một khoa chưa dùng LMS
MNAR	thiếu phụ thuộc chính giá trị bị thiếu: sinh viên điểm thấp không làm khảo sát

- ▶ Loại bỏ: chấp nhận được khi MCAR và tỷ lệ thiếu nhỏ.
- ▶ Với MNAR, mọi phương pháp điền đều có thể gây chệch; cần phân tích độ nhạy.

Siêu dữ liệu và phả hệ dữ liệu

Siêu dữ liệu nghiệp vụ

Tên chỉ số, ý nghĩa, đơn vị, chủ sở hữu, quy tắc tính.

Siêu dữ liệu kỹ thuật

Nguồn, lược đồ, kiểu, phân vùng, lịch cập nhật, quy trình ETL.

Phả hệ dữ liệu (lineage)

Một bảng được dẫn xuất từ nguồn nào, qua những phép biến đổi nào.

- ▶ Siêu dữ liệu là nền tảng của **quản trị dữ liệu** (*data governance*).

Ba vùng dữ liệu: thô, đã xử lý, phục vụ

Vùng thô (raw / bronze)

Bất biến, giữ nguyên định dạng nguồn kèm thời điểm nạp; cho phép xử lý lại.

Vùng đã xử lý (cleaned / silver)

Lược đồ chuẩn, đã khử trùng lặp và kiểm tra quy tắc; định dạng Parquet.

Vùng phục vụ (curated / gold)

Bảng tổng hợp, kho dữ liệu chuyên đề (data mart), đặc trưng cho học máy.

MỤC 2.3

Lưu trữ dữ liệu và điện toán đám mây

Hiệu suất, khả năng mở rộng, chi phí; nền tảng nội bộ, công cộng và lai


Điện toán đám mây: định nghĩa NIST

Định nghĩa NIST [Mell & Grance, 2011]: **điện toán đám mây** (*cloud computing*) là mô hình truy cập qua mạng, theo nhu cầu, tới tập tài nguyên tính toán dùng chung, cấp phát và thu hồi nhanh với nỗ lực quản lý tối thiểu.

- ▶ Năm đặc tính: tự phục vụ; truy cập mạng rộng; gộp tài nguyên; co giãn nhanh; dịch vụ được đo lường.

Mô hình dịch vụ và mô hình triển khai


- ▶ Ba mô hình **dạng dịch vụ**: IaaS (máy ảo, lưu trữ), PaaS (nền tảng, dịch vụ dữ liệu được quản lý), SaaS (ứng dụng).
- ▶ Bốn mô hình triển khai: riêng, cộng đồng, công cộng, lai.
- ▶ Co giãn biến CAPEX thành OPEX [Armbrust et al., 2010].



Hình 2.18: Ranh giới trách nhiệm trong SaaS, PaaS, IaaS. Theo bài giảng KHDL

Tách tính toán và lưu trữ

(a) Gắn kết: cụm HDFS + Spark



mở rộng theo cặp tính toán–lưu trữ;
tận dụng tính cục bộ dữ liệu

(b) Tách rời: cụm tính toán + lưu trữ đối tượng



co giãn độc lập; tắt cụm khi rảnh;
nhiều engine dùng chung dữ liệu

Hình 2.19: Kiến trúc gắn kết và tách rời tính toán–lưu trữ. Nguồn: tác giả tổng hợp

Tách rời tính toán–lưu trữ: lợi ích và chi phí

Ưu điểm của tách rời

Trả tiền tính toán theo thời gian sử dụng; dung lượng lưu trữ tăng không kéo theo máy chủ; nhiều nhóm và công cụ dùng chung một bản dữ liệu.

Chi phí phải trả

Mất tính cục bộ dữ liệu; băng thông mạng trở thành nút cổ chai; độ trễ mỗi yêu cầu cao hơn. Bù đắp bằng định dạng cột, nén, cắt tỉa phân vùng và bộ nhớ đệm.

Tầng lưu trữ nóng, ấm, lạnh và vòng đời dữ liệu

Tầng	Tần suất truy cập	Độ trễ truy xuất	Giá lưu trữ/GB	Phí truy xuất	Ví dụ trong trường
Nóng	thường xuyên	mili giây	cao	thấp hoặc không	dữ liệu học kỳ hiện tại
Ấm	vài lần mỗi tháng	mili giây	trung bình	có	dữ liệu các năm gần
Lạnh / lưu trữ	hiếm	phút đến giờ	thấp	cao; có thời gian lưu tối thiểu	nhật ký kiểm toán dài hạn

- **Chính sách vòng đời** (lifecycle policy): tự động chuyển đổi tượng xuống tầng thấp hơn theo tuổi.

Mô hình chi phí và điểm hòa vốn

Chi phí đám mây hằng tháng

$$C = \sum_i S_i p_i + Q p_q + E p_e + H p_h$$

S_i : dung lượng ở tầng i ; Q : số yêu cầu; E : dữ liệu truyền ra; H : giờ máy tính toán.

Ví dụ (giả định)

Đơn vị tiền quy ước (đvt). Nội bộ: đầu tư ban đầu 100 đvt, vận hành 2 đvt/tháng. Đám mây: 5 đvt/tháng.

$$100 + 2t = 5t \Rightarrow t^* \approx 33 \text{ tháng.}$$

Nếu tải chỉ cần trong 40% thời gian và cụm được tắt khi rảnh, chi phí đám mây giảm còn 2 đvt/tháng và không có điểm hòa vốn.

Truyền dữ liệu ra (egress)

- ▶ Nhà cung cấp đám mây công cộng thường không tính phí dữ liệu vào nhưng tính phí dữ liệu ra khỏi vùng hoặc khỏi nhà cung cấp.
- ▶ **Trọng lực dữ liệu** (data gravity): dữ liệu lớn khó di chuyển, kéo ứng dụng và tính toán về gần nó.
- ▶ Thiết kế giảm truyền ra: tính toán cùng vùng với dữ liệu; chỉ xuất kết quả tổng hợp; nén và dùng định dạng cột.
- ▶ Chi phí truyền ra là một nguồn chính gây **phụ thuộc nhà cung cấp** (vendor lock-in).

Hiệu năng truy cập: thời gian quét song song

Thời gian quét song song

$T \approx \frac{D}{n \cdot b}$, với D : dữ liệu phải đọc; n : số nút; b : băng thông đọc mỗi nút.

(giả định) $D = 10 \text{ TB}$, $n = 50$, $b = 200 \text{ MB/s} \Rightarrow T \approx 1000 \text{ s}$.

Chỉ đọc 5/50 cột (định dạng cột) và 1/12 phân vùng tháng (cắt tỉa phân vùng):

$$D' \approx 10 \text{ TB} \times 0,1 \times \frac{1}{12} \approx 83 \text{ GB} \Rightarrow T' \approx 8 \text{ s}.$$

Lưu trữ đối tượng còn chịu giới hạn tốc độ yêu cầu và chi phí liệt kê; nhiều tệp nhỏ làm giảm hiệu năng, cần gộp tệp (compaction).

Cam kết mức dịch vụ (SLA)

SLA (service-level agreement) quy định [D1, 3.5.3]:

- ▶ chỉ số đo và cách đo chất lượng dịch vụ;
- ▶ mức cam kết (ví dụ tỷ lệ thời gian sẵn sàng);
- ▶ cách báo cáo kết quả đánh giá;
- ▶ bồi thường (tín dụng dịch vụ) khi vi phạm;
- ▶ cơ chế giải quyết tranh chấp.

Độ bền dữ liệu (durability, xác suất không mất dữ liệu) khác với **tính sẵn sàng** (*availability*) (khả năng truy cập tại một thời điểm).

Nội bộ, đám mây công cộng và mô hình lai


Tiêu chí	Nội bộ (on-premise)	Đám mây công cộng	Lai (hybrid)
Cấu trúc chi phí	CAPEX lớn, OPEX ổn định	OPEX theo mức dùng	kết hợp; tối ưu theo tải
Khả năng co giãn	giới hạn bởi phần cứng đã mua	gần như tức thời	co giãn phần chạy trên đám mây
Kiểm soát, chủ quyền	đầy đủ	phụ thuộc vị trí trung tâm dữ liệu và hợp đồng	dữ liệu nhạy cảm giữ nội bộ
Bảo mật, tuân thủ	tự thực hiện toàn bộ	trách nhiệm chia sẻ	phức tạp hơn do hai môi trường

Không có phương án vượt trội tuyệt đối. Tiêu chí kỹ năng, thời gian triển khai, phụ thuộc nhà cung cấp: xem Tài liệu đọc thêm.

Cụm HDFS và lưu trữ đối tượng (S3, GCS, ADLS)

Tiêu chí	Cụm HDFS (nội bộ)	Lưu trữ đối tượng (đám mây)
Truy cập	đường dẫn tệp, <code>hdfs://</code>	API theo bucket/khóa: <code>s3a://</code> , <code>gs://</code> , <code>abfss://</code>
Tính cục bộ	tính toán đặt cạnh khối dữ liệu	dữ liệu đọc qua mạng
Mở rộng	thêm nút; siêu dữ liệu của NameNode giới hạn số tệp	gần như không giới hạn, do nhà cung cấp quản lý
Ngữ nghĩa	đổi tên thư mục nguyên tử	đổi tên = sao chép + xóa; liệt kê tốn kém
Độ bền	sao chép (mặc định 3 bản)	do nhà cung cấp bảo đảm theo cam kết
Chi phí	phần cứng, điện, nhân sự	GB-tháng, yêu cầu, truyền ra

Kiến trúc lai và chủ quyền dữ liệu



Hình 2.20: Kiến trúc lai: dữ liệu nhạy cảm ở nội bộ, tính toán co giãn trên đám mây. Nguồn: tác giả tổng hợp

Chủ quyền dữ liệu và khung pháp lý


- ▶ **Chủ quyền dữ liệu:** dữ liệu chịu điều chỉnh của pháp luật nơi lưu trữ, xử lý.
- ▶ Văn bản cần xem xét: Luật An ninh mạng (2018), Nghị định 53/2022/NĐ-CP; Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân; Luật Dữ liệu (2024).
- ▶ Dữ liệu người học là dữ liệu cá nhân: cần phân loại mức nhạy cảm, kiểm soát truy cập.
- ▶ Mô hình lai tận dụng cơ giãn mà vẫn giữ dữ liệu nhạy cảm trong phạm vi kiểm soát.

Ma trận quyết định lựa chọn nền tảng lưu trữ

Tiêu chí	w_i	Nội bộ	Công cộng	Lai
Bảo mật, chủ quyền dữ liệu	0,30	5	2	4
Tổng chi phí sở hữu 3 năm	0,25	3	4	3
Khả năng co giãn	0,15	2	5	4
Kỹ năng sẵn có	0,15	4	2	3
Thời gian triển khai	0,15	2	5	4
Điểm tổng hợp S_j		3,45	3,40	3,60

$S_j = \sum_i w_i s_{ij}$, $\sum_i w_i = 1$; trọng số và điểm (thang 1–5) là giả định minh họa. Chênh lệch nhỏ nên kết quả nhạy với trọng số: cần thống nhất trọng số trước khi chấm và phân tích độ nhạy.

Tình huống: luồng ETL của NEU IO Portal



Hình 2.21: Luồng dữ liệu của NEU IO Portal (vẽ lại). Theo [TT-NEU]

NEU IO Portal: đặc điểm và hướng mở rộng


Đặc điểm

Dữ liệu từ các hệ thống nghiệp vụ trên Oracle và MySQL được rút trích, chuyển đổi và nạp vào kho dữ liệu tập trung; front-end cung cấp xem dữ liệu, phân quyền, trực quan hóa và API cho các bên khai thác.

Phân tích và hướng mở rộng

ETL theo lô phù hợp báo cáo định kỳ nhưng hạn chế độ tươi. Có thể bổ sung CDC + Kafka cho dữ liệu cần cập nhật nhanh, hồ dữ liệu cho dữ liệu bán/phi cấu trúc (nhật ký LMS) và danh mục siêu dữ liệu, phủ hệ.

Pipeline thu thập cho trung tâm dữ liệu đại học



Hình 2.22: Đề xuất pipeline thu thập cho trung tâm dữ liệu đại học. Nguồn: tác giả tổng hợp

Tình huống: quyết định thiết kế và đánh đổi

Quyết định	Phương án đề xuất	Lý do	Đánh đổi
Thu thập điểm, đăng ký học phần	CDC → Kafka	cần độ tươi theo giờ; phát hiện sửa/xóa điểm	vận hành Kafka Connect, xử lý thay đổi lược đồ
Danh mục, dữ liệu tham chiếu	Sqoop / Spark JDBC, lô đêm	ít thay đổi, khối lượng nhỏ	độ trễ đến 24 giờ
Sự kiện LMS	agent → Kafka, khóa phân vùng là mã SV	khối lượng lớn, nhiều bên tiêu thụ	thứ tự chỉ bảo đảm theo sinh viên
Nền tảng	lai	dữ liệu cá nhân ở nội bộ; tính toán co giãn cho dữ liệu ẩn danh	phức tạp vận hành hai môi trường

Đề xuất cho mục đích thảo luận; định dạng lưu trữ và chất lượng dữ liệu: xem Tài liệu đọc thêm.

Câu hỏi thảo luận

1. **Phân tích (2.2).** Vì sao CDC dựa trên nhật ký giao dịch thường được ưu tiên hơn truy vấn theo cột thời gian cập nhật? Khi nào lựa chọn ngược lại hợp lý hơn?
2. **Phân tích (2.1).** Sau khi tích hợp một nguồn mới, dashboard cho thấy tỷ lệ sinh viên có nguy cơ tăng mạnh. Làm sao phân biệt thay đổi thực với sai lệch do tích hợp (trùng lặp, đổi định nghĩa, thiếu dữ liệu)?
3. **Đánh giá (2.3).** Trong mô hình chi phí của mục 2.3, tham số nào làm dịch chuyển điểm hòa vốn? Khi nào mô hình lai có lợi hơn cả hai phương án thuần?

Các câu hỏi thiết kế (quy tắc chất lượng sáu chiều; ước lượng partition Kafka cho LMS) và câu hỏi chuyển đổi Flume/Sqoop sang Kafka/CDC: xem Tài liệu đọc thêm Chương 2.

Tóm tắt chương

Vòng đời	Thu thập → khám phá → tiền xử lý → phân tích → giải thích kết quả → hành động; có vòng phản hồi.
Thu thập	Lô, đẩy, luồng, CDC: đánh đổi độ trễ, tải nguồn và độ phức tạp vận hành.
Khám phá, truyền đạt	EDA bằng thuật toán xấp xỉ và lấy mẫu; trực quan hóa theo câu hỏi và người ra quyết định.
Tích hợp	ETL/ELT; Kafka làm trực sự kiện; Flume, Sqoop, NiFi, CDC theo đặc trưng nguồn.
Chất lượng	Sáu chiều đo được; khử trùng lặp, đối sánh thực thể, giá trị thiếu.
Lưu trữ, đám mây	Tách tính toán—lưu trữ, tầng lưu trữ, mô hình chi phí; chọn nội bộ, công cộng, lai bằng ma trận quyết định.

Chương 3 đi sâu vào các hệ thống lưu trữ (HDFS, NoSQL, CAP) và mô hình xử lý theo lô, tương tác, luồng.