

HỌC PHẦN

Xử lý dữ liệu lớn

Big Data — Chương trình Thạc sĩ Khoa học máy tính

Chương 1 — Giới thiệu dữ liệu lớn và thách thức

TS. Vũ Ngọc Thanh Sang

Khoa Công nghệ Thông tin — Trường Đại học Sài Gòn

MTDL522
3 tín chỉ

MỤC 1.1

Ứng dụng và công nghệ của dữ liệu lớn

Từ nhu cầu ứng dụng đến sự ra đời của các công nghệ xử lý dữ liệu lớn

Bối cảnh: dữ liệu phát sinh từ mọi hoạt động



Hình 1.1: Các nhóm nguồn sinh dữ liệu.


Theo bài giảng Xử lý dữ liệu lớn (CNTT)

NĂM NHÓM NGUỒN SINH DỮ LIỆU

Giao dịch	Bán lẻ, ngân hàng, thương mại điện tử
Máy móc	Nhật ký máy chủ, Internet vạn vật (IoT), cảm biến
Hành vi số	Luồng nhấp chuột, tìm kiếm, ứng dụng di động
Nội dung	Văn bản, ảnh, video, mạng xã hội
Doanh nghiệp	ERP, CRM, hồ sơ, hợp đồng

Luận điểm: dữ liệu thay đổi cả về kích thước, tốc độ, cấu trúc và mức độ liên kết; do vậy bài toán dữ liệu lớn trước hết là bài toán thiết kế hệ thống.

Từ dữ liệu đến quyết định và hành động



Hình 1.2: Chuỗi giá trị từ dữ liệu đến hành động. Nguồn: tác giả tổng hợp

Giá trị của dữ liệu lớn chỉ được hiện thực hóa khi chuỗi khép kín đến **hành động** và tạo dữ liệu phản hồi; đây là cơ sở của **ra quyết định dựa trên dữ liệu** (*data-driven decision making*).

Ứng dụng theo khâu của chuỗi giá trị

Bán hàng

Dự báo nhu cầu theo cửa hàng–mặt hàng–ngày; định giá động; tối ưu tồn kho và khuyến mãi.

Tiếp thị

Phân khúc khách hàng; cá nhân hóa và gợi ý; đo lường hiệu quả chiến dịch; dự báo rời bỏ.

Sản xuất–cung ứng

Bảo trì dự đoán từ cảm biến; kiểm soát chất lượng; tối ưu tuyến vận chuyển.

Ứng dụng trong tài chính, y tế, giao thông

Sand

Tài chính — ngân hàng

Phát hiện gian lận thẻ gần thời gian thực; chấm điểm tín dụng; chống rửa tiền dựa trên phân tích mạng giao dịch.

Mist

Y tế


Hồ sơ sức khỏe điện tử; phân tích ảnh y khoa; giám sát bệnh nhân bằng thiết bị đeo; dịch tễ học.

Sand

Giao thông vận tải

Ước lượng thời gian di chuyển từ GPS; phát hiện ùn tắc; điều khiển tín hiệu; quy hoạch tuyến đường.

Bản đồ ứng dụng theo tốc độ và tính đa dạng



Hình 1.3: Ứng dụng theo tốc độ và tính đa dạng. Theo bài giảng KHDL (trích từ giáo trình)

- ▶ **Trục đứng:** yêu cầu độ trễ, từ **xử lý theo lô** (*batch*) đến thời gian thực.
- ▶ **Trục ngang:** mức độ cấu trúc, từ bảng quan hệ đến văn bản, video.

Hàm ý thiết kế: vị trí trên bản đồ quyết định kiến trúc: xử lý theo lô, **xử lý luồng** (*stream*) hay kết hợp; lưu trữ quan hệ hay hồ dữ liệu.

Thách thức chính trong các lĩnh vực ứng dụng

Lĩnh vực	Thách thức dữ liệu	Thách thức kỹ thuật	Thách thức quản trị, pháp lý
Mạng xã hội	Văn bản nhiều, tiếng lóng, tài khoản ảo, tin giả	Đồ thị hàng tỷ cạnh; lan truyền theo thời gian thực	Quyền riêng tư; kiểm duyệt nội dung
Giao thông vận tải	GPS sai số, lấy mẫu thưa, camera đa định dạng	Truy vấn không gian—thời gian liên tục; dự báo ngắn hạn	Dữ liệu vị trí dễ tái định danh cá nhân
Tài chính	Mất cân bằng lớp (gian lận hiếm); dữ liệu lệch thời gian	Độ trễ mili giây; tính nhất quán giao dịch	Tuân thủ, kiểm toán, giải thích được mô hình
Y học	Hồ sơ không đồng nhất; ảnh dung lượng lớn; thiếu nhãn	Tích hợp đa nguồn; tính toán trên ảnh và gen	Dữ liệu nhạy cảm; đồng thuận của bệnh nhân

Thách thức xuyên suốt và khung pháp lý


Thách thức xuyên suốt

- ▶ Dữ liệu phân tán trên nhiều hệ thống.
- ▶ Thiếu **siêu dữ liệu** (*metadata*) và chủ sở hữu dữ liệu.
- ▶ Chi phí lưu trữ, xử lý tăng nhanh.
- ▶ Thiếu nhân lực vận hành hệ phân tán.

Khung pháp lý tại Việt Nam

- ▶ Luật Dữ liệu số 60/2024/QH15.
- ▶ Luật Bảo vệ dữ liệu cá nhân số 91/2025/QH15.
- ▶ Thu thập, xử lý phải xét mục đích, quyền của chủ thể dữ liệu và trách nhiệm các bên.


Cách tiếp cận truyền thống và nút cổ chai



Hình 1.4: Mô hình xử lý truyền thống. Theo

- ▶ **Hệ thống tập trung** (*centralised system*) lưu trữ và xử lý trên CSDL quan hệ thương mại; hợp với dữ liệu có cấu trúc.
- ▶ Dữ liệu tăng: mọi luồng dồn về một điểm, tạo **nút cổ chai** (*bottleneck*).
- ▶ Mở rộng **theo chiều dọc** (*scale-up*): chi phí phi tuyến, có giới hạn; “cần có giải pháp hiệu quả hơn”.

Giải pháp của Google: GFS và MapReduce




phần cứng phổ thông

Hình 1.5: Mô hình xử lý dữ liệu lớn của Google.
Theo


- ▶ **GFS** (Ghemawat et al., 2003): **hệ thống tệp phân tán** (*distributed file system*); tệp chia khối lớn, mỗi khối có nhiều **bản sao** (*replica*).
- ▶ **MapReduce** (Dean & Ghemawat, 2004): chia nhiệm vụ thành phần nhỏ, giao cho nhiều máy, rồi tổng hợp kết quả.

Nguyên lý MapReduce và tính cục bộ dữ liệu



- ▶ Sự cố phần cứng là trạng thái thường trực; **khả năng chịu lỗi** (*fault tolerance*) được bảo đảm ở **mức phần mềm**.
- ▶ Tính toán được đưa đến nút chứa dữ liệu: **tính cục bộ dữ liệu** (*data locality*). Chi tiết: Chương 3–4.

Hadoop: hiện thực mã nguồn mở




Hình 1.6: Mô hình xử lý dữ liệu lớn của Hadoop. Theo


- Doug Cutting và cộng sự phát triển Hadoop theo giải pháp của Google ; dự án Apache từ 2006.

Spark: tính toán trong bộ nhớ

Xử lý bằng MapReduce



Xử lý bằng Spark



Hình 1.7: So sánh cách hoạt động của MapReduce và Spark. Theo

Từ Hadoop đến Spark

- ▶ Hadoop MapReduce ghi kết quả trung gian xuống đĩa sau mỗi bước: chậm với thuật toán lặp.
- ▶ Spark: kết quả trung gian giữ trong **bộ nhớ trong** (*in-memory*): lợi thế với thuật toán lặp.
- ▶ Khởi đầu năm 2009 tại AMPLab; chuyển giao cho Apache năm 2013 .
- ▶ **Tập dữ liệu phân tán bền vững** (*Resilient Distributed Dataset, RDD*) chịu lỗi nhờ **phả hệ** (*lineage*) [Zaharia et al., 2012].
- ▶ Đánh đổi: phụ thuộc dung lượng RAM; dữ liệu vượt bộ nhớ tràn xuống đĩa.

MỤC 1.2

Những điều cơ bản để làm việc với dữ liệu lớn

Đặc tính của dữ liệu lớn; khai phá dữ liệu; mô hình dữ liệu; phát biểu bài toán

Định nghĩa dữ liệu lớn

Laney (2001), META Group

Thách thức quản lý dữ liệu tăng theo ba chiều: **khối lượng** (Volume), **tốc độ** (Velocity) và **tính đa dạng** (Variety).

Gartner (2012)

“Dữ liệu lớn là tài sản thông tin có khối lượng lớn, tốc độ cao và/hoặc tính đa dạng cao, đòi hỏi các hình thức xử lý thông tin hiệu quả về chi phí và đổi mới, nhằm tăng cường **hiểu biết sâu sắc** (*insight*), ra quyết định và tự động hóa quy trình.”


Định nghĩa dữ liệu lớn: nhận xét

De Mauro, Greco & Grimaldi (2016)

Tài sản thông tin có khối lượng, tốc độ, tính đa dạng cao đến mức cần công nghệ và phương pháp phân tích riêng để chuyển thành giá trị.

- ▶ “Lớn” là khái niệm **tương đối**: phụ thuộc công cụ, ngân sách, thời hạn phản hồi và kiến trúc hiện có .
- ▶ Không có ngưỡng GB/TB cố định cho mọi bài toán.
- ▶ Dấu hiệu nhận dạng: hệ thống phải **thay đổi kiến trúc**, không chỉ nâng cấp phần cứng.
- ▶ Định nghĩa của Gartner gắn đặc tính dữ liệu với **mục đích**: insight, quyết định, tự động hóa.


Từ 3V đến 6V: các đặc tính của dữ liệu lớn



Hình 1.10: Mô hình sáu đặc tính (6V). Nguồn: tác giả tổng hợp

- Học phần sử dụng **mô hình 6V**; ba V đầu mô tả **quy mô**, ba V sau mô tả **chất lượng, cấu trúc và mục đích**.

Khối lượng (Volume)



Định nghĩa làm việc

Khối lượng: quy mô dữ liệu cần lưu trữ và xử lý, vượt khả năng của một máy trong thời hạn yêu cầu.

Hình 1.11: Các bậc dung lượng dữ liệu. Theo bài giảng

Xử lý dữ liệu lớn (CNTT)


Tốc độ (Velocity)

HAI THÀNH PHẦN CỦA TỐC ĐỘ

- ▶ **Tốc độ phát sinh:** số sự kiện đến mỗi giây λ .
- ▶ **Yêu cầu phản hồi:** độ trễ chấp nhận được từ khi sự kiện xảy ra đến khi có hành động.

Bài toán	Dữ liệu đến	Phản hồi
Phát hiện gian lận	Giao dịch liên tục	Mili giây–giây
Cảnh báo ùn tắc	GPS, camera	Giây–phút
Cá nhân hóa web	Luồng nhấp chuột	Trong phiên
Báo cáo doanh thu	Giao dịch tích lũy	Giờ–ngày

Tính đa dạng (Variety)



Hình 1.12: Dữ liệu có cấu trúc, bán cấu trúc và phi cấu trúc.

Theo bài giảng Xử lý dữ liệu lớn (CNTT)

- ▶ **Dữ liệu có cấu trúc** (*structured*): bảng, lược đồ cố định.
- ▶ **Bán cấu trúc** (*semi-structured*): JSON, XML, nhật ký; cấu trúc tự mô tả, linh hoạt.
- ▶ **Phi cấu trúc** (*unstructured*): văn bản, ảnh, âm thanh, video.

Tính xác thực (Veracity)

Định nghĩa

Tính xác thực phản ánh mức độ chính xác, đầy đủ và đáng tin của dữ liệu, cùng độ bất định của các kết luận rút ra từ dữ liệu đó.

NGUỒN GÂY SAI LỆCH

- ▶ Cảm biến lệch, mất kết nối; GPS sai số.
- ▶ Nhật ký thiếu trường, sai định dạng, lệch múi giờ.
- ▶ Người dùng nhập không nhất quán; tài khoản ảo, bot.
- ▶ Các nguồn mâu thuẫn; lược đồ thay đổi theo thời gian.

Tính liên kết (Valence)

Định nghĩa

Tính liên kết (*Valence*) đo mức độ các phần tử dữ liệu kết nối với nhau. Dữ liệu có tính liên kết cao khi tỷ lệ phần tử có quan hệ trực tiếp với phần tử khác lớn.

ĐỘ ĐO TRÊN ĐỒ THỊ $G = (V, E)$, $n = |V|$, $m = |E|$


$$\delta(G) = \frac{2m}{n(n-1)},$$

$$\bar{k} = \frac{2m}{n}$$

δ : mật độ liên kết (đồ thị vô hướng); $\bar{k}$: bậc trung bình. Với đồ thị có hướng:
 $\delta = m/(n(n-1))$.

- ▶ Ví dụ: quan hệ bạn bè, trích dẫn, giao dịch giữa tài khoản, cùng tham gia lớp học phần.

Tính liên kết: ví dụ và hệ quả xử lý



Hình 1.13: Cùng tập phần tử, tính liên kết tăng theo thời gian.

Nguồn: tác giả tổng hợp

Hệ quả xử lý

Liên kết dày làm truy vấn nhiều bước nhảy, **phân vùng** (*partitioning*) dữ liệu và truyền thông giữa các nút trở nên đắt (Chương 3–4).

Giá trị (Value)

Định nghĩa


Giá trị là lợi ích đạt được hoặc có tiềm năng đạt được từ quá trình khoa học dữ liệu, thể hiện qua quyết định và hành động tốt hơn.

GIÁ TRỊ RÒNG CỦA MỘT DỰ ÁN DỮ LIỆU

$$G = \Delta B - (C_{\text{thu}} + C_{\text{lưu}} + C_{\text{xử lý}} + C_{\text{quản trị}})$$

ΔB : lợi ích tăng thêm (doanh thu, tiết kiệm, rủi ro giảm); các C : chi phí theo vòng đời dữ liệu.

Các mức phân tích và giá trị



- ▶ Không phải dữ liệu nào thu thập được cũng nên lưu giữ vô thời hạn.
- ▶ Với bài toán cần phản hồi nhanh, giá trị giảm theo độ trễ.

Hình 1.14: Các mức phân tích và giá trị. Nguồn: tác giả tổng hợp

Đọc một bài toán qua sáu đặc tính

Đặc tính	Câu hỏi phân tích	Quyết định kiến trúc liên quan
Volume	Dữ liệu lớn đến mức nào? Tăng bao nhiêu mỗi tháng?	Phân tán lưu trữ, nén, phân vùng, vòng đời dữ liệu
Velocity	Dữ liệu đến nhanh đến đâu? Cần phản hồi trong bao lâu?	Xử lý theo lô, luồng hay kết hợp
Variety	Bao nhiêu nguồn, định dạng, ngữ nghĩa?	Mô hình dữ liệu, lược đồ khi ghi hay khi đọc
Veracity	Dữ liệu thiếu, nhiễu, mâu thuẫn ở mức nào?	Kiểm tra chất lượng, làm sạch, truy vết nguồn gốc
Valence	Các phần tử liên kết dày đến đâu? Có thay đổi theo thời gian?	Mô hình đồ thị, chiến lược phân hoạch
Value	Kết quả hỗ trợ quyết định gì? Ai sử dụng?	Độ đo thành công, ưu tiên đầu tư

Đánh đổi giữa các đặc tính

- ▶ Tốc độ cao làm giảm thời gian dành cho làm sạch (Velocity $\leftrightarrow$ Veracity).
- ▶ Lưu tất cả dữ liệu thô tăng chi phí nhưng giữ khả năng khai thác về sau (Volume $\leftrightarrow$ Value).
- ▶ Liên kết dày làm phân vùng kém hiệu quả (Valence $\leftrightarrow$ khả năng mở rộng).

Ví dụ: học tập trực tuyến qua sáu đặc tính

Đặc tính	Biểu hiện và hệ quả
Volume	Hàng chục nghìn người học × nhiều sự kiện mỗi phiên, tích lũy nhiều năm
Velocity	Đỉnh tải theo lịch thi, hạn nộp bài; cảnh báo cần theo tuần
Variety	Bảng điểm, nhật ký JSON, văn bản diễn đàn, video bài giảng
Veracity	Đăng nhập hộ, mã sinh viên không thống nhất giữa hệ thống
Valence	Mạng sinh viên–học phần–nhóm; quan hệ tiên quyết giữa học phần
Value	Cảnh báo sớm nguy cơ bỏ học; cải tiến chương trình đào tạo

Kết luận: khối lượng có thể chưa vượt một máy, nhưng Variety, Veracity và yêu cầu tích hợp khiến đây là bài toán dữ liệu lớn về **tích hợp và quản trị**.

Khai phá dữ liệu là gì?

Định nghĩa (Fayyad, Piatetsky-Shapiro & Smyth, 1996)

Phát hiện tri thức trong cơ sở dữ liệu (*Knowledge Discovery in Databases, KDD*) là quá trình không tầm thường nhằm nhận diện các mẫu **hợp lệ, mới, có ích tiềm năng** và **có thể hiểu được** trong dữ liệu. **Khai phá dữ liệu** (*data mining*) là bước áp dụng thuật toán để trích xuất mẫu trong quá trình đó.

Trong thực tế, phần lớn công sức nằm ở lựa chọn, tiền xử lý và biến đổi dữ liệu (Chương 2); bước khai phá chỉ là một khâu.

Các tác vụ khai phá dữ liệu

Tác vụ	Nhóm	Ví dụ trên dữ liệu lớn	Thuật toán tiêu biểu
Phân lớp (<i>classification</i>)	Dự đoán	Giao dịch gian lận hay hợp lệ	Hồi quy logistic, cây quyết định
Hồi quy (<i>regression</i>)	Dự đoán	Thời gian di chuyển trên một tuyến	Hồi quy tuyến tính, GBM
Phân cụm (<i>clustering</i>)	Mô tả	Phân khúc khách hàng; cụm quỹ đạo	k-means, DBSCAN
Luật kết hợp (<i>association rules</i>)	Mô tả	Giỏ hàng: $X \Rightarrow Y$; học phần thường đăng ký cùng	Apriori, FP-growth
Phát hiện bất thường (<i>anomaly detection</i>)	Mô tả	Lỗi cảm biến; xâm nhập mạng	Isolation Forest, thống kê

Khai phá ở quy mô lớn: điều gì thay đổi?

Thuật toán / tác vụ	Độ phức tạp	Vấn đề khi n rất lớn	Hướng xử lý
k-means	$O(nkdl)$	Mỗi vòng lặp quét toàn bộ dữ liệu	Lưu đệm trong bộ nhớ (Spark); mini-batch
Độ tương tự từng cặp, kNN	$O(n^2d)$	Bùng nổ số cặp	Băm nhay cục bộ (LSH); lấy mẫu
Apriori	Tới $O(2^{ I })$ ứng viên	Bùng nổ tập ứng viên; nhiều lần quét	FP-growth song song
Mô hình tuyến tính	$O(nd)$ mỗi lượt	Dữ liệu không vừa bộ nhớ	SGD, huấn luyện phân tán
Bất thường trên luồng	$O(1)$ mỗi sự kiện	Không lưu được toàn bộ lịch sử	Cửa sổ thời gian, cấu trúc phức tạp

Mô hình dữ liệu là gì?

Định nghĩa (Codd, 1980)

Mô hình dữ liệu (*data model*) là sự kết hợp của ba thành phần: (1) tập kiểu **cấu trúc** dữ liệu; (2) tập **phép toán** trên cấu trúc đó; (3) tập **ràng buộc** toàn vẹn.

- ▶ Mô hình dữ liệu khác với **lược đồ** (một thể hiện cụ thể theo mô hình) và khác với **mô hình học máy** (hàm dự đoán).
- ▶ Lựa chọn mô hình dữ liệu quyết định loại truy vấn hiệu quả, cách phân vùng và khả năng mở rộng.

So sánh các mô hình dữ liệu (1/2)

Mô hình	Thế mạnh	Hạn chế	Phù hợp
Quan hệ	Ràng buộc chặt, ACID, SQL giàu biểu đạt	Khó mở rộng ngang với phép kết nối lớn; lược đồ cứng	Giao dịch, báo cáo có cấu trúc
Tài liệu (JSON)	Lược đồ linh hoạt; dữ liệu lồng nhau đọc một lần	Kết nối giữa tài liệu kém; trùng lặp dữ liệu	Hồ sơ người dùng, danh mục sản phẩm
Khóa–giá trị	Đọc/ghi theo khóa rất nhanh; dễ phân vùng	Không truy vấn theo giá trị; logic ở ứng dụng	Phiên làm việc, bộ đệm, đếm


So sánh các mô hình dữ liệu (2/2)

Mô hình	Thế mạnh	Hạn chế	Phù hợp
Cột rộng	Ghi khối lượng lớn; quét theo khoảng khóa	Thiết kế khóa hàng khó; truy vấn hạn chế	Chuỗi thời gian, nhật ký, cảm biến
Đồ thị	Truy vấn nhiều bước nhảy; biểu đạt quan hệ	Phân vùng khó; xử lý toàn đồ thị tốn kém	Mạng xã hội, gợi ý, chống gian lận

Nguyên tắc lựa chọn

Chọn mô hình theo **mẫu truy vấn chủ đạo** và đặc tính dữ liệu (Variety, Valence), không theo xu hướng công nghệ. Hệ thống lớn thường dùng nhiều mô hình song song (polyglot persistence). Chi tiết các hệ NoSQL: Chương 3.

Lược đồ khi ghi và lược đồ khi đọc




Hình 1.15: Hai cách áp đặt lược đồ. Nguồn: tác giả tổng hợp

Khi ghi (*schema-on-write*): chất lượng kiểm soát tốt, truy vấn nhanh; kém linh hoạt khi nguồn thay đổi; chi phí ETL ban đầu cao.

Khi đọc (*schema-on-read*): linh hoạt với dữ liệu đa dạng; cần quản trị siêu dữ liệu tốt để tránh “đầm lầy dữ liệu”.

Phát biểu bài toán dữ liệu lớn



Hình 1.16: Bảy thành phần của một phát biểu bài toán. Nguồn: tác giả tổng hợp

- Ràng buộc hệ thống (độ trễ, chi phí, quyền riêng tư) là điểm phân biệt bài toán dữ liệu lớn với bài toán phân tích thông thường.

Dạng phát biểu hình thức

Cho dữ liệu $\mathcal{D}$ thu từ các nguồn $S_1, \dots, S_r$ với đặc tính $(V_1, \dots, V_6)$, biểu diễn theo mô hình dữ liệu $\mathcal{M}$; tìm $\hat{f} \in \mathcal{F}$ cho tác vụ $\mathcal{T}$:

$$\hat{f} = \arg \max_{f \in \mathcal{F}} M(f; \mathcal{D})$$


với điều kiện: độ trễ $\leq L$, chi phí $\leq B$, tuân thủ chính sách dữ liệu P .

- ▶ Gắn với chu trình CRISP-DM: hiểu nghiệp vụ $\rightarrow$ hiểu dữ liệu $\rightarrow$ chuẩn bị $\rightarrow$ mô hình hóa $\rightarrow$ đánh giá $\rightarrow$ triển khai [Chapman et al., 2000].

Ví dụ: cảnh báo sớm nguy cơ bỏ học

Thành phần	Nội dung
Mục tiêu nghiệp vụ	Giảm tỷ lệ sinh viên bỏ học bằng can thiệp sớm của cố vấn học tập.
Câu hỏi phân tích	Sinh viên nào có nguy cơ bỏ học trong học kỳ tới, xét tại tuần thứ 6?
Dữ liệu	Nhật ký LMS, điểm danh, điểm quá trình, học phí, khảo sát (Variety, Veracity cao).
Mô hình dữ liệu	Bảng đặc trưng theo sinh viên–tuần (từ nhật ký JSON); đồ thị sinh viên–nhóm học.
Tác vụ	Phân lớp nhị phân $y \in \{0, 1\}$; đặc trưng x tổng hợp đến tuần 6.
Độ đo	Độ phủ (<i>recall</i>) và F1 cho lớp “bỏ học” (lớp hiếm); không dùng accuracy đơn thuần.
Ràng buộc	Cập nhật hằng tuần; phân quyền dữ liệu cá nhân; mô hình giải thích được cho cố vấn.
Rủi ro	Rò rỉ dữ liệu tương lai vào đặc trưng; thiên lệch với nhóm sinh viên ít dùng LMS.

Nhận dạng một bài toán dữ liệu lớn




Hình 1.17: Cây quyết định nhận dạng bài toán dữ liệu lớn. Nguồn: tác giả tổng hợp

MỤC 1.3

Case study

Giao thông, Twitter, web và mạng xã hội, Google web search, gợi ý phim và nhạc; case Việt Nam

Giao thông: bối cảnh và nguồn dữ liệu



Hình 1.18: Nguồn dữ liệu và ứng dụng trong giao thông. Nguồn: tác giả tổng hợp

Giao thông qua sáu đặc tính


- ▶ **Volume**: hàng triệu điểm GPS mỗi ngày; video liên tục.
- ▶ **Velocity**: cảnh báo ùn tắc chỉ có giá trị trong vài phút (D1).
- ▶ **Variety**: chuỗi tọa độ, ảnh, video, bản đồ vector.
- ▶ **Veracity**: sai số GPS ở đô thị, lấy mẫu thưa, mất tín hiệu.
- ▶ **Valence**: quỹ đạo gắn với mạng đường; đoạn đường kề nhau.
- ▶ **Value**: giảm thời gian di chuyển, tối ưu vận hành.

Mô hình dữ liệu không gian–thời gian

CÁC ĐỐI TƯỢNG DỮ LIỆU

- ▶ **Điểm GPS:** $p_i = (o, t_i, \varphi_i, \lambda_i, v_i, \theta_i)$: đối tượng, thời điểm, vĩ độ, kinh độ, tốc độ, hướng.
- ▶ **Quỹ đạo:** $T_o = \langle p_1, \dots, p_n \rangle$ với $t_1 < \dots < t_n$.
- ▶ **Mạng đường:** đồ thị có hướng $G = (V, E)$ (giao lộ, đoạn đường).
- ▶ **Khớp bản đồ** (map matching): $\mu : p_i \mapsto e \in E$.
- ▶ **Chuỗi thời gian theo đoạn:** $s(e, \tau) = \frac{1}{|P_{e,\tau}|} \sum_{p \in P_{e,\tau}} v_p$, với $P_{e,\tau}$: các điểm khớp vào đoạn e trong khung τ (ví dụ 15 phút).

Quy trình khai thác dữ liệu di chuyển



- ▶ Trực quan hóa ma trận $s(e, \tau)$ (xem Tài liệu đọc thêm Chương 1) cho thấy hai đỉnh giờ cao điểm và **sự cố cục bộ**.
- ▶ Mẫu thường xuyên hỗ trợ quy hoạch, phân cụm quỹ đạo phân tích luồng giao thông, phân lớp dự đoán hành vi (D1).

Twitter: bài toán và cấu trúc dữ liệu

MỘT TWEET (RÚT GỌN, BÁN CẤU TRÚC)

```
{
  "id": "1790...",
  "created_at": "2024-05-12T08:31Z",
  "user": { "id": "42",
            "followers": 1530 },
  "text": "Kẹt xe #giaothong",
  "hashtags": ["giaothong"],
  "retweet_of": null,
  "coordinates": [106.72, 10.80],
  "lang": "vi"
}
```

Ví dụ minh họa, không phải dữ liệu thật.

CÂU HỎI PHÂN TÍCH

- ▶ Chủ đề nào nổi lên, khi nào, ở đâu?
- ▶ Cảm xúc cộng đồng về một sự kiện thay đổi ra sao?
- ▶ Thông tin lan truyền qua những tài khoản nào?


Twitter: quy trình phân tích



Hình 1.19: Quy trình phân tích và trực quan hóa dữ liệu Twitter. Nguồn: tác giả tổng hợp

- ▶ Văn bản mạng xã hội chứa viết tắt, tiếng lóng, biểu tượng cảm xúc: tiền xử lý là bắt buộc.
- ▶ Ở quy mô lớn: chạy song song trên Spark (Chương 4–5).

Twitter: trực quan hóa dữ liệu lớn



Hình 1.20: Chồng lấp điểm, tổng hợp mật độ và giảm mẫu chuỗi thời gian (dữ liệu mô phỏng). Nguồn: tác giả tổng hợp

Twitter: chồng lấp, tổng hợp, giảm mẫu

Chồng lấp (overplotting)

Số điểm vượt độ phân giải màn hình; mật độ thực bị che khuất.

Tổng hợp, lấy mẫu

Đếm theo ô lục giác, nhóm theo vùng; lấy mẫu phân tầng để giữ nhóm hiếm.

Giảm mẫu chuỗi thời gian

Theo mức thu phóng; giữ min-max mỗi khung để không mất đỉnh đột biến.

Tiến hóa web và hệ quả đối với dữ liệu


- ▶ **Web 1.0** (chỉ đọc, nội dung tĩnh) → **Web 2.0** (đọc–ghi, nội dung do người dùng tạo, đồ thị xã hội) → **Web 3.0** (ngữ nghĩa: siêu dữ liệu, ontology).

HỆ QUẢ ĐỐI VỚI DỮ LIỆU (D1)

- ▶ Kiến trúc web đa tầng phục vụ hàng triệu người dùng làm bùng nổ dữ liệu giao dịch (**Volume**).
- ▶ Nội dung do người dùng tạo chuyển dữ liệu sang bán cấu trúc và phi cấu trúc (**Variety**).
- ▶ Quan hệ giữa người dùng và trang tạo dữ liệu có tính liên kết cao (**Valence**).


Mô hình đồ thị cho web và mạng xã hội

Đồ thị web




có hướng
(siêu liên kết)

Đồ thị xã hội



một chế độ
(bạn bè, theo dõi)

Người dùng–mục



hai chế độ
(hai phía)

Hình 1.21: Ba dạng đồ thị điển hình trên web. Nguồn: tác giả tổng hợp

Phân tích mạng xã hội: độ đo và quy luật

ĐỘ ĐO TRUNG TÂM của nút v

$$C_D(v) = \frac{\deg(v)}{n-1}, \quad C_C(v) = \frac{n-1}{\sum_{u \neq v} d(v, u)}, \quad C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

$d(v, u)$: khoảng cách ngắn nhất; σ_{st} : số đường ngắn nhất từ s đến t ; $\sigma_{st}(v)$: số đường đó đi qua v .

QUY LUẬT CẤU TRÚC (D1)

- ▶ **Luật lũy thừa:** $P(k) \propto k^{-\gamma}$; số ít nút có rất nhiều liên kết.
- ▶ **Thế giới nhỏ:** khoảng cách trung bình ngắn; lan truyền nhanh.


Truy vấn quan hệ: bảng và đồ thị

Truy vấn	Bảng quan hệ	Đồ thị
Bạn của v	1 phép kết nối	Duyệt 1 bước
Bạn của bạn	2 phép kết nối	Duyệt 2 bước
Đường đi $\leq k$ bước	k phép kết nối, chi phí tăng nhanh	Duyệt k bước theo cạnh
Thống kê theo cột	Hiệu quả	Kém hiệu quả

Nhận xét


Mô hình đồ thị phù hợp với truy vấn quan hệ nhiều bước; mô hình bảng/cột phù hợp với tổng hợp. Nền tảng thực tế thường giữ cả hai.

Google web search: tổng quan hệ thống



Hình 1.22: Luồng dữ liệu của một máy tìm kiếm web. Nguồn: tác giả tổng hợp

Xây dựng chỉ mục ngược bằng MapReduce



Hình 1.23: Chỉ mục ngược bằng MapReduce. Nguồn: tác giả tổng hợp

PageRank: mô hình người duyệt ngẫu nhiên

$$PR(v) = \frac{1-d}{N} + d \sum_{u \in \text{In}(v)} \frac{PR(u)}{\text{deg}^+(u)}$$

d : hệ số tắt dần, thường $d = 0,85$; N : số trang; $\text{In}(v)$: các trang trỏ tới v ;
 $\text{deg}^+(u)$: số liên kết ra của u [Page et al., 1999].


- ▶ Xác suất d : theo một liên kết; $1 - d$: nhảy ngẫu nhiên.
- ▶ Trang không có liên kết ra được phân bổ đều.

PageRank: dạng ma trận và ví dụ

DẠNG MA TRẬN VÀ PHÉP LẬP LỮ THỪA

$$\mathbf{r}^{(k+1)} = dM\mathbf{r}^{(k)} + \frac{1-d}{N}\mathbf{1}$$

với $M_{vu} = 1/\deg^+(u)$; $\mathbf{r}$ là phân phối dừng của chuỗi Markov; hội tụ sau vài chục vòng lặp.



Hình 1.24: PageRank hội tụ trên đồ thị 4 trang

($d = 0,85$). Nguồn: tác giả tổng hợp

Khởi tạo $r_v = 0,25$. Vòng 1: (0,250; 0,144; 0,569; 0,038). Vòng 2: (0,521; 0,144; 0,298; 0,038). C nhận liên kết từ ba trang nên có hạng cao nhất; D không được trở tới nên chỉ nhận phần nhảy ngẫu nhiên $(1-d)/N$.

Bài toán gợi ý: ký hiệu và loại phản hồi

- ▶ Ma trận $R \in \mathbb{R}^{m \times n}$; tập ô quan sát Ω ; độ thưa $1 - |\Omega|/(mn)$ thường rất gần 1.
- ▶ Mục tiêu: dự đoán $\hat{r}_{ui}$ cho $(u, i) \notin \Omega$ và đề xuất top- N .
- ▶ **Phản hồi tường minh**: điểm đánh giá phim (1–5 sao).
- ▶ **Phản hồi ngầm**: số lần nghe bài hát, thời lượng xem; dồi dào nhưng nhiều, không có phản hồi âm [Hu et al., 2008].

Lọc cộng tác dựa trên lân cận

LỌC CỘNG TÁC THEO MỤC [Sarwar et al., 2001]

$$\text{sim}(i, j) = \frac{\sum_u r_{ui} r_{uj}}{\sqrt{\sum_u r_{ui}^2} \sqrt{\sum_u r_{uj}^2}}, \quad \hat{r}_{ui} = \frac{\sum_{j \in N_k(i) \cap I_u} \text{sim}(i, j) r_{uj}}{\sum_{j \in N_k(i) \cap I_u} |\text{sim}(i, j)|}$$

$N_k(i)$: k mục tương tự nhất với i ; I_u : các mục người dùng u đã đánh giá.

- ▶ **Lọc cộng tác** (*collaborative filtering*): dùng hành vi của cộng đồng, không cần nội dung của mục.
- ▶ Theo mục ổn định hơn theo người dùng khi số người dùng rất lớn.

Phân rã ma trận

$$\begin{matrix} \boxed{R} \\ m \times n \end{matrix} \approx \begin{matrix} \boxed{P} \\ m \times k \end{matrix} \times \begin{matrix} \boxed{Q^T} \\ k \times n \end{matrix}$$

Hình 1.25: Phân rã ma trận với $k \ll \min(m, n)$. Nguồn: tác giả tổng hợp

HÀM MỤC TIÊU [Koren, Bell & Volinsky, 2009]

$$\min_{P, Q} \sum_{(u, i) \in \Omega} (r_{ui} - \mathbf{p}_u^\top \mathbf{q}_i)^2 + \lambda (\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2)$$

$\mathbf{p}_u, \mathbf{q}_i \in \mathbb{R}^k$: véc-tơ nhân tố ẩn; λ : hệ số **chính quy hóa** (*regularization*). Có thể bổ sung độ lệch người dùng, mục và động học theo thời gian.

Bình phương tối thiểu luân phiên (ALS)


Cố định Q , bài toán theo từng $\mathbf{p}_u$ là bình phương tối thiểu có nghiệm đóng; sau đó cố định P để giải $\mathbf{q}_i$:

$$\mathbf{p}_u = (\mathbf{Q}_u^\top \mathbf{Q}_u + \lambda \mathbf{I}_k)^{-1} \mathbf{Q}_u^\top \mathbf{r}_u$$

$\mathbf{Q}_u$: các hàng của Q ứng với mục u đã đánh giá; $\mathbf{r}_u$: các đánh giá tương ứng.


- ▶ Mỗi $\mathbf{p}_u$ giải **độc lập**: song song hóa tự nhiên theo người dùng, rồi theo mục.
- ▶ Chi phí mỗi lượt: $O(|\Omega|k^2 + (m+n)k^3)$.
- ▶ Hỗ trợ phản hồi ngầm bằng trọng số tin cậy [Hu et al., 2008].

Case Việt Nam: Viettel Data Platform



Hình 1.26: Kiến trúc Viettel Data Platform. Theo

Case Việt Nam: mô hình NEU IO Portal



Hình 1.27: Mô hình hệ thống NEU IO Portal. Theo

Câu hỏi thảo luận

1. **Đánh giá:** Một bộ dữ liệu 50 GB có thể là bài toán dữ liệu lớn không? Biện luận bằng các đặc tính 6V và cây quyết định ở Hình 1.17.
2. **Phân tích:** Tính liên kết (Valence) tăng theo thời gian ảnh hưởng thế nào đến chiến lược phân vùng dữ liệu và ước lượng tài nguyên?
3. **Thiết kế:** Phát biểu bài toán “dự báo nhu cầu chỗ đỗ xe trong khuôn viên trường” theo bảy thành phần ở Hình 1.16; chọn mô hình dữ liệu và giải thích.
4. **Thiết kế:** Đề xuất kiến trúc theo tầng cho trung tâm dữ liệu lớn của Trường Đại học Sài Gòn; so sánh với NEU IO Portal.

Bộ đầy đủ sáu câu hỏi: xem Tài liệu đọc thêm Chương 1.

Bài tập tự học và bài đọc

THỰC HÀNH: EX_C1.IPYNB

1. Nhật ký tìm kiếm theo giờ; tỷ lệ chuyển đổi, tỷ lệ thoát; giới hạn của Pandas khi dữ liệu tăng 1.000 lần.
2. MapReduce với PySpark.
3. NetworkX; PageRank so với độ trung tâm bậc.
4. Phân tích cảm xúc tiếng Việt; Veracity.

Tóm tắt chương

- ▶ **Ứng dụng (1.1.1):** giá trị đến khi khép kín chuỗi dữ liệu—quyết định—hành động; thách thức riêng về dữ liệu, kỹ thuật, pháp lý.
- ▶ **Công nghệ (1.1.2):** tập trung → GFS, MapReduce → Hadoop → Spark → đám mây, hồ—kho; các thể hệ chồng lớp, cùng tồn tại.
- ▶ **Đặc tính (1.2.1):** 6V; giữa các V có đánh đổi.
- ▶ **Khai phá, mô hình dữ liệu (1.2.2):** tác vụ dự đoán/mô tả; cấu trúc + phép toán + ràng buộc; lược đồ khi ghi/khi đọc.
- ▶ **Phát biểu bài toán (CLO3):** mục tiêu → câu hỏi → dữ liệu → mô hình dữ liệu → tác vụ → độ đo → ràng buộc.
- ▶ **Case study (1.3):** không gian—thời gian; trực quan hóa luồng; đồ thị web; PageRank; ma trận thưa, ALS; Viettel, NEU IO.

Tài liệu tham khảo (1/2)

HỌC LIỆU CỦA HỌC PHẦN

- [1] A. Bahga, V. Madiseti. *Big Data Analytics: A Hands-On Approach*. VPT, 2019.
- [2] P. Gentsch. *AI in Marketing, Sales and Service*. Palgrave Macmillan, 2019.
- [3] D. K. Mishra, X.-S. Yang, A. Unal (eds.). *Data Science and Big Data Analytics*. Springer, 2019.
- [4] P. Zikopoulos et al. *Harness the Power of Big Data*. McGraw-Hill, 2012.
- [5] T. White. *Hadoop: The Definitive Guide*, 4th ed. O'Reilly, 2015.
- [6] D. Miner, A. Shook. *MapReduce Design Patterns*. O'Reilly, 2012.

Lê Việt Thuỷ, Nguyễn Văn Hoàng. Xây dựng trung tâm dữ liệu lớn cho hệ thống đại học thông minh. Hội thảo khoa học quốc gia “Ứng dụng CNTT trong đổi mới phương pháp giảng dạy theo hướng Blended Learning”, tr. 209–218.

Tài liệu tham khảo (2/2)

- ▶ D. Laney. 3D Data Management: Controlling Data Volume, Velocity, and Variety. META Group, 2001.
- ▶ U. Fayyad, G. Piatetsky-Shapiro, P. Smyth. From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 1996.
- ▶ S. Ghemawat, H. Gobioff, S.-T. Leung. The Google File System. *SOSP*, 2003.
- ▶ J. Dean, S. Ghemawat. MapReduce: Simplified Data Processing on Large Clusters. *OSDI*, 2004.
- ▶ M. Zaharia et al. Resilient Distributed Datasets. *NSDI*, 2012.
- ▶ L. Page, S. Brin, R. Motwani, T. Winograd. The PageRank Citation Ranking. Stanford InfoLab, 1999.
- ▶ Y. Koren, R. Bell, C. Volinsky. Matrix Factorization Techniques for Recommender Systems. *IEEE Computer*, 2009.

Danh mục đầy đủ: Tài liệu đọc thêm Chương 1.

Xử lý dữ liệu lớn — Chương 1: Giới thiệu dữ liệu lớn